

Ingeniería de Características

Preparando el "alimento" de la Inteligencia Artificial - Nivel II

Parte 1: Variables Categóricas

El Desafío de los Datos

Formatos Crudos

Los algoritmos de aprendizaje automático operan en espacios vectoriales matemáticos. No pueden interpretar directamente conceptos cualitativos como "Rojo" o "Bajo".

Necesidad de Transformación

Sin la ingeniería de características, los modelos fallarían al intentar procesar texto o escalas incompatibles, perdiendo señales críticas.

Técnicas de Transformación



One-Hot Encoding

Crea columnas binarias individuales para cada categoría. Ideal cuando no hay orden intrínseco (Nominal).



Label Encoding

Asigna un número único secuencial. Útil para modelos basados en árboles que capturan relaciones numéricas.



Codificación Ordinal

Asigna valores basados en un orden lógico predefinido (ej. Bajo=1, Medio=2, Alto=3).

Profundizando en One-Hot


Lógica de Estructura

Transformamos una columna con N categorías en N nuevas columnas binarias.

En Python con Pandas:

```
df_encoded = pd.get_dummies(df, columns=['color'])
```

Este proceso garantiza que el modelo no asuma una jerarquía falsa entre elementos independientes como colores o marcas.




Label & Ordinal

El Valor del Orden

Cuando existe una jerarquía lógica (como niveles de calidad o satisfacción), el mapeo ordinal es la herramienta más potente.

Permite al modelo capturar la magnitud de la diferencia entre categorías, mejorando la precisión en problemas de regresión y clasificación estructurada.

Modeling Journey: From Concept to Implementation



Parte 2: Escalado de Datos

Impacto en el Entrenamiento

100x


Velocidad de Convergencia

Por qué escalar importa

Los algoritmos basados en distancias (k-NN, SVM) o gradiente descendente (Redes Neuronales) se ven dominados por variables con magnitudes grandes.


El escalado asegura que un "Salario" de 50,000 no opaque a una "Edad" de 30, dando a cada característica el peso justo.

Tendencia de Convergencia




Los datos escalados permiten al algoritmo encontrar el mínimo global de forma mucho más eficiente y estable.

Pilares del Escalado



Estandarización

Transforma datos a media 0 y desviación 1 (Z-score). Ideal para SVM y Redes Neuronales.



Normalización

Escala al rango [0, 1] (Min-Max). Vital cuando los datos no siguen una distribución normal.

¿Por qué es **Vital**?

- **Reducción de Sesgos:** Evita que el modelo priorice variables erróneamente basándose solo en su magnitud numérica absoluta.
 - **Eficiencia Matemática:** Garantiza que los gradientes se mantengan estables, acelerando drásticamente el tiempo de entrenamiento.
 - **Compatibilidad Universal:** Permite fusionar información cualitativa (nombres) con cuantitativa (pesos) en un solo vector de entrada.
-

¿Preguntas?

Ingeniería de Características: La clave del éxito en IA






Image Sources



<https://media.geeksforgeeks.org/wp-content/uploads/20250701114435618562/feature-engineering.webp>

Source: www.geeksforgeeks.org



https://miro.medium.com/1*PS0uHJj7Z8lnNk5ogbOVzw.png

Source: medium.com



https://miro.medium.com/v2/resize:fit:1400/1*9MMVNrwTXuK mz5Es6SCM4A.png

Source: medium.com



https://miro.medium.com/1*ot4GbgWWE5mauH6wSdcLgQ.png

Source: medium.com
