

Visualización Científica

Análisis Exploratorio y Preparación de Datos - Nivel II

El Ecosistema Python

Matplotlib vs. Seaborn

Matplotlib: La Base

Es el "padre" de la visualización. Brinda control total sobre cada línea, eje y marcador. Es la herramienta para personalización profunda en gráficos científicos.

Seaborn: Estadística

Capa superior optimizada para estadística. Facilita la creación de gráficos complejos con poco código y detecta automáticamente estructuras de Pandas.

Patrones: Histogramas y KDE

Entendiendo la Distribución

Permiten ver qué valores son comunes y cuáles extremos. La línea KDE muestra la "forma" de los datos.


Clave: Una campana indica normalidad; múltiples picos sugieren la existencia de subgrupos distintos en la población.



Correlaciones con Heatmaps

Matriz de Relaciones

Visualiza cómo interactúan las variables (ej. Edad vs. Presión). Los valores cercanos a 1 indican una correlación positiva fuerte.



Scatter Plots

Espacio y Relación

Muestran cómo interactúan dos variables numéricas. El parámetro *hue* añade una tercera dimensión mediante colores.

Insight: Las líneas ascendentes claras revelan relaciones directas fundamentales para el modelado.



El Flujo del Nivel II



Univariado

Analiza una variable a la vez (Histogramas) para entender su distribución única.



Multivariado

Explora la relación entre múltiples variables para hallar dependencias y grupos.



Insights

Detecta anomalías (outliers) y hallazgos valiosos para el entrenamiento de IA.

El Poder del Pairplot

Vista Panorámica (EDA)

La Diagonal

Muestra la distribución individual (Histograma o KDE) de cada característica del dataset.

Fuera de Diagonal

Muestra diagramas de dispersión cruzando cada par de variables para identificar clusters al instante.

Impacto en el Modelo

EDA

Identificación Crítica

Si los grupos (Sanos vs. Enfermos) se separan visualmente en el pairplot, has hallado variables discriminantes potentes.

Aviso temprano: Si los datos están muy mezclados, sabrás que el modelo tendrá dificultades de precisión.

¿Por qué es Vital?

- ✓ **Detección de Outliers:** Limpieza de errores de medición antes de entrenar.
 - ✓ **Relaciones No Lineales:** Selección del kernel adecuado para SVM o k-NN.
 - ✓ **Validación de Ingeniería:** Confirmar que las transformaciones mejoran la separación.
 - ✓ **Ahorro de Tiempo:** Evita entrenar modelos con variables que no aportan señal real.
-

¿Preguntas?

Visualización Científica: Transformando datos en Inteligencia


Uneweb | Nivel II: Análisis, Limpieza y Visualización

Image Sources



https://miro.medium.com/v2/resize:fit:1400/1*dySZaEBWcafsvPvPhhu9A.png

Source: medium.com



<https://blogs.sas.com/content/iml/files/2019/09/DensityPlot4.png>

Source: blogs.sas.com
