

Análisis Exploratorio de Datos (EDA)

Técnicas Fundamentales para el Éxito en Inteligencia Artificial

¿Qué es el EDA?

"Interrogar" los datos para descubrir su estructura, detectar anomalías y entender variables útiles.

| Importancia del Análisis Previo

Etapa Crítica

El EDA es la etapa más importante antes de entrenar cualquier modelo. Permite conocer qué tienes en las manos antes de aplicar algoritmos complejos.

Objetivo Principal

Validar la calidad, encontrar patrones ocultos y verificar si las suposiciones estadísticas para el modelado son correctas.

| Inspección Estructural

El "Check-up" de Datos

Utilizamos herramientas de Pandas para una inspección rápida:

 `.info()` : Verifica tipos y nulos.

 `.describe()` : Estadísticas básicas.

 `.head()` / `.tail()` : Integridad visual.

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 126314 entries, 0 to 126313
Data columns (total 23 columns):
gameorder      126314 non-null int64
game_id        126314 non-null object
lg_id          126314 non-null object
_iscopy        126314 non-null int64
year_id        126314 non-null int64
date_game      126314 non-null object
seasongame     126314 non-null int64
is_playoffs    126314 non-null int64
team_id        126314 non-null object
fran_id        126314 non-null object
pts            126314 non-null int64
elo_i          126314 non-null float64
elo_n          126314 non-null float64
win_equiv      126314 non-null float64
opp_id         126314 non-null object
opp_fran       126314 non-null object
opp_pts        126314 non-null int64
opp_elo_i      126314 non-null float64
opp_elo_n      126314 non-null float64
game_location  126314 non-null object
game_result    126314 non-null object
forecast       126314 non-null float64
notes          5424 non-null object
dtypes: float64(6), int64(7), object(10)
memory usage: 22.2+ MB
```


| Nulos y Duplicados

Garbage In, Garbage Out

Un modelo con datos sucios aprenderá basura. Es vital identificar el porcentaje de datos faltantes antes de decidir.

Decisiones de Limpieza

Eliminar: Si la pérdida es mínima.


Imputar: Usar media o mediana si el volumen es crítico.

| Análisis Univariado

Distribuciones y Outliers

Observamos cómo se comporta cada variable de forma aislada.
Los **Boxplots** son esenciales para detectar valores atípicos.

¿Son errores de sensor o casos reales interesantes?





Análisis Multivariado

Buscando Conexiones

Identificamos qué variables están conectadas mediante:

-  **Matriz de Correlación:** ¿Se mueven juntas?
-  **Pairplot:** Cruce total de variables para detectar clusters.



| Impacto en el Modelo



Evitar Sesgos

Eliminar redundancia y multicolinealidad que confunden al modelo.



Limpieza Inteligente

Distinguir errores de casos especiales que el modelo debe aprender.



Selección Algoritmo

Decidir entre modelos lineales o no lineales (Random Forest, SVM).

| Selección de Estrategia

-  **Relación Lineal:** Si las nubes de puntos en Scatter Plots son rectas, usa modelos lineales simples.
-  **Relación No Lineal:** Si no hay separación clara, opta por Random Forest o Kernels RBF.
-  **Reducción:** Elimina variables con alta correlación para simplificar el aprendizaje.

| La Regla de Oro

70%

Esfuerzo en EDA

Un consejo profesional: Dedicar el 70% de tu tiempo al EDA y la limpieza.

Solo el 30% restante debe dedicarse al entrenamiento. El éxito depende de los datos, no solo del algoritmo.

| Flujo del EDA Profesional




¿Preguntas?

"Un modelo mediocre con datos limpios vence a un modelo avanzado con datos sucios."


Análisis Exploratorio de Datos (EDA)

Image Sources




<https://files.realpython.com/media/info.80fdd50f4ff7.png>

Source: [realpython.com](https://files.realpython.com/media/info.80fdd50f4ff7.png)



https://miro.medium.com/v2/resize:fit:1400/1*0MPDTLn8KoLApoFvI0P2vQ.png

Source: [medium.com](https://miro.medium.com/v2/resize:fit:1400/1*0MPDTLn8KoLApoFvI0P2vQ.png)



<https://i.sstatic.net/AfXmd.png>

Source: [stackoverflow.com](https://i.sstatic.net/AfXmd.png)