

Dominar la Evaluación de Modelos

Desafíos técnicos y métricas avanzadas: Recall, Validación

Cruzada y Estrategias de Kaggle.

| El Secreto de la Evaluación



Desbalanceo

Enfrentar datasets donde una clase predomina masivamente sobre la otra.



Validación Cruzada

Garantizar que los resultados sean estables y no fruto del azar.



Recall Crítico

Priorizar la detección de positivos, vital en contextos médicos y de fraude.


3 Recomendaciones Estratégicas

Para dominar estas técnicas, no necesitamos datos "grandes", sino datos con **"dolores" específicos** que nos obliguen a usar métricas avanzadas.

- ✓ Credit Card Fraud (Desbalanceo)
- ✓ Heart Disease UCI (Reto Clínico)
- ✓ Telco Customer Churn (Reto de Negocio)

3 RECOMENDACIONES ESTRATÉGICAS: DOMINAR TÉCNICAS DE EVALUACIÓN

PARA DOMINAR ESTAS TÉCNICAS, NO NECESITAMOS DATOS "GRANDES", SINO DATOS CON "DOLORES" ESPECÍFICOS QUE NOS OBLIGUEN A USAR MÉTRICAS AVANZADAS



1. Credit Card Fraud Detection


El Rey del Desbalanceo

El 99.8% de los datos son normales. La precisión simple es una métrica engañosa aquí.

- ✓ Uso de **SMOTE** para balancear.
- ✓ **Matriz de Confusión** para Falsos Negativos.
- ✓ **Stratified K-Fold** para integridad.

RECOMENDACIÓN ESTRATÉGICA PRINCIPAL: DOMINAR LA DETECCIÓN DE FRAUDE

ENFRENTANDO 'EL REY DEL DESBALANCEO' CON ESTRATEGIAS DE DATOS Y MÉTRICAS AVANZADAS




2. Heart Disease UCI

El Reto Clínico

En medicina, el costo de un Falso Negativo es potencialmente fatal.

- ✓ **Validación Cruzada** para diversos perfiles.
- ✓ **Recall Crítico** como prioridad.
- ✓ Limpieza de nulos y datos categóricos.



Resumen de Flujo de Validación

Dataset	Objetivo Principal	Métrica Clave
Credit Card	Detectar Intrusos	Recall (No dejar pasar fraudes)
Heart Disease	Diagnóstico Médico	Recall (Prioridad salvar vidas)
Customer Churn	Retención de Clientes	F1-Score (Equilibrio Costo/Beneficio)

Deep Dive: Heart Disease UCI

Configuración del entorno y limpieza robusta para diagnóstico clínico.

Pasos Fundamentales



Limpieza

Eliminar IDs irrelevantes e imputar valores nulos (mediana/moda).



Transformación

Uso de `pd.get_dummies` para convertir texto a señales numéricas.



Validación

Aplicar K-Fold Estratificado para representar todos los estados clínicos.

Entendiendo la Variable 'num'


Presencia y Severidad

Es el atributo objetivo (target) que el modelo debe predecir:

- ✓ **0:** Ausencia (Paciente Sano).
- ✓ **1, 2, 3, 4:** Grados de severidad clínica.
- ✓ **Clasificación Binaria:** Simplificar a Sano (0) vs. Enfermo (1).

ENTENDIENDO LA VARIABLE 'NUM' Y EL AJUSTE DEL TARGET CLÍNICO

ES EL ATRIBUTO OBJETIVO (TARGET) QUE EL MODELO DEBE PREDECIR:



Implementación Técnica

```
# Imputación de nulos y codificación
for col in df.columns:
    if df[col].dtype in ['float64', 'int64']:
        df[col] = df[col].fillna(df[col].median())
    else:
        df[col] = df[col].fillna(df[col].mode()[0])

df_encoded = pd.get_dummies(df, drop_first=True)
```

Esta limpieza robusta evita que los valores faltantes rompan el modelo y traduce el lenguaje humano a matemáticas.

| Entrenamiento y Validación

100

Árboles de Decisión independientes (Random Forest)
para reducir el error por consenso.

5

Pliegues (Folds) en la Validación Cruzada para asegurar
la estabilidad del diagnóstico.

¿Garantiza el éxito?

El manejo de nulos, la transformación total y la validación estratificada son los pilares de un diagnóstico confiable.