

OLLAMA: IA LOCAL Y PRIVADA

Despliegue de modelos de lenguaje en tu propia infraestructura

¿QUÉ ES OLLAMA?

El motor que permite ejecutar modelos de IA de clase mundial en tu hardware

CAPACIDADES DEL SISTEMA



GESTIÓN

Descarga y actualiza modelos como Llama 3, Mistral o Phi-3 de forma automática.



SERVIDOR

Crea una API local (localhost:11434) lista para integraciones profesionales.



OPTIMIZACIÓN

Carga inteligente en memoria aprovechando al máximo la CPU y GPU NVIDIA/Apple.

OLLAMA VS CLOUD APIS

Característica	Ollama (Local)	Nube (OpenAI / GPT)
Privacidad	Total (Datos nunca salen de tu red)	Limitada (Datos viajan a terceros)
Costo Operativo	Gratuito (Solo consumo eléctrico)	Pago por uso (Token-based)
Conectividad	Funciona 100% Offline	Requiere Internet constante
Flexibilidad	Alta (Cambia de modelo al instante)	Atado a las versiones del proveedor

REQUISITOS TÉCNICOS

Preparando tu equipo para la inferencia de alta velocidad

MEMORIA DE SISTEMA

16


GB RAM MÍNIMO

FLUIDEZ EN MODELOS 7B/8B

Para modelos como Mistral o Llama 3, contar con 16GB asegura que el sistema no use memoria en disco (swap), evitando una latencia excesiva en las respuestas.

ESTRATEGIAS DE HARDWARE

- ⚡ Cuantización: Comprime modelos de 14GB a 4-5GB sin perder inteligencia apreciable.
- ⚡ VRAM Crítica: Con una GPU de 8GB, la respuesta es casi instantánea para modelos medianos.
- 🌿 Modelos Ligeros: Usa Llama 3.2:3b o Phi-3 para equipos con recursos limitados.



MODEL-AS-A-SERVICE

Llevando el prototipo local a un entorno de producción escalable

| MAAS EN PRODUCCIÓN

-  **Serving & Contenedores:** Uso de Docker y motores como vLLM o TGI para optimizar el throughput mediante batching dinámico.
 -  **Orquestación:** Kubernetes para gestionar múltiples instancias y balanceo de carga entre GPUs.
 -  **Observabilidad:** Monitoreo de latencia, calidad de respuesta y métricas de "drift" para evitar alucinaciones.
- Seguridad:** Autenticación OAuth y sanitización de prompts para prevenir ataques de "Prompt Injection".

| EL PIPELINE RAG

INGESTA

Carga de archivos y
división en chunks.

EMBEDDINGS

Vectorización semántica
del texto.

V-DB

Indexación en ChromaDB
para búsqueda.

RESPUESTA




Generación de IA basada
en contexto.

ASISTENTE RAG LOCAL

UN CHATBOT INTELIGENTE

Este sistema permite consultar documentos privados (PDF/DOCX) sin que la información salga del equipo.

- ✓ Orquestado con LangChain
- ✓ Base Vectorial ChromaDB
- ✓ Interfaz Web Streamlit




¿PREGUNTAS?

Inicia tu propio servidor de IA privada hoy mismo.

[WWW.OLLAMA.COM](https://www.ollama.com) | [@OLLAMA_AI](https://twitter.com/OLLAMA_AI)

IMAGE SOURCES



<https://www.scalecomputing.com/images/SEO/gpu-architecture-diagram.png>

Source: www.scalecomputing.com



<https://cdn.dribbble.com/userupload/47005506/file/f971c96087a48816222e374c8ae00a33.png?resize=752x&vertical=center>

Source: dribbble.com
